Optimización de MAXIM con expertos: resumen

Nov 4, 2026 · @Mati

Objetivo y resultado principal

Reemplazamos un bloque pesado de MAXIM por expertos pequeños, uno por tarea. El modelo bajó **13,5 % sus parámetros frente al baseline, de 14,18 M a 12,26 M**, sin perder calidad en test. Un módulo pequeño común, con el mismo costo, sí pierde calidad. Llevar los expertos también al nivel intermedio de la red duplica la reducción de FLOPs, pero pierde 0,26 dB en derain en test y baja la latencia sólo 2,3 %.

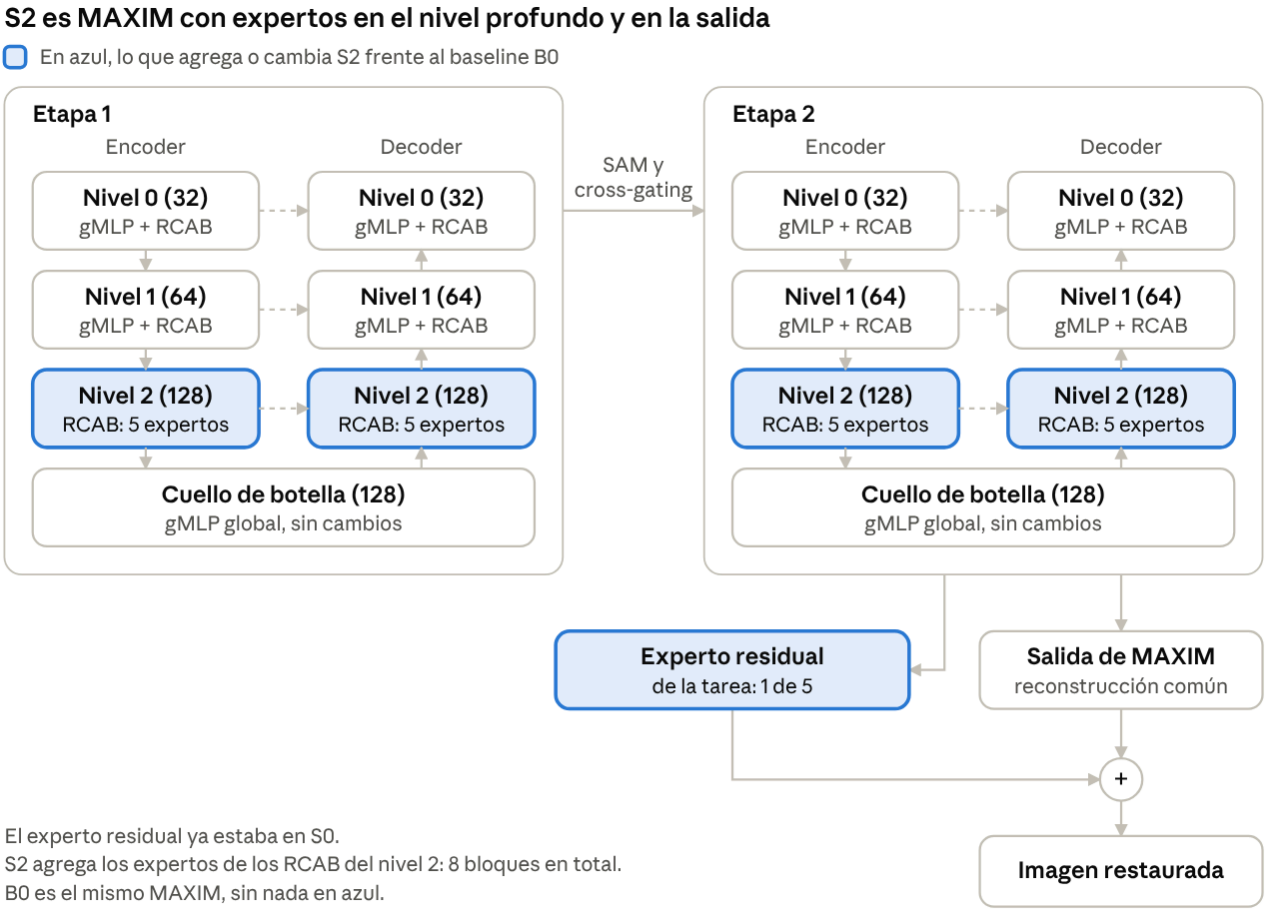
El objetivo de esta fase era reducir el tamaño y el costo de MAXIM aprovechando los expertos por tarea. Partimos de dos modelos ya entrenados, MAXIM S-2 con cinco tareas: deblur, dehaze, denoise, derain y enhance.

- **Baseline (B0):** MAXIM sin expertos.
- **Shared (S0):** el mismo MAXIM, cuya reconstrucción es común a todas las tareas, más cinco expertos residuales chicos, uno por tarea. Cada experto suma una corrección a esa reconstrucción. La tarea de cada imagen se conoce de antemano y se pasa al modelo: no hay router que la decida.

En el test del 4 de octubre, shared y baseline daban prácticamente la misma calidad, con +0,009 dB de PSNR macro. Por eso la fase se orientó a costo y no a mejorar calidad.

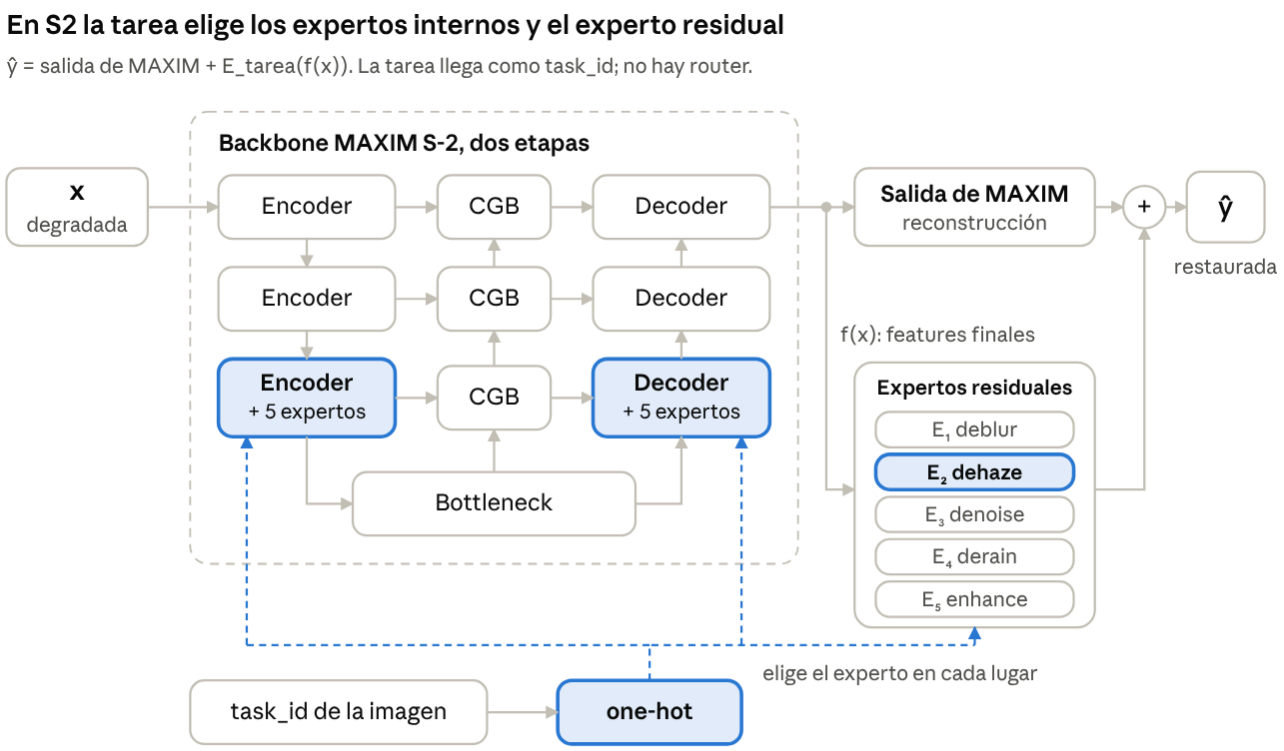
Qué reemplazamos

Reemplazamos las convoluciones de los ocho bloques RCAB del nivel más profundo de la red, con 128 canales: **2,36 M parámetros, el 16,7 % del baseline**. Lo elegimos con el benchmark de costo: es una parte grande del modelo y su reemplazo no cambia la estructura de MAXIM.



MAXIM S-2, vista general · B0 frente a S2

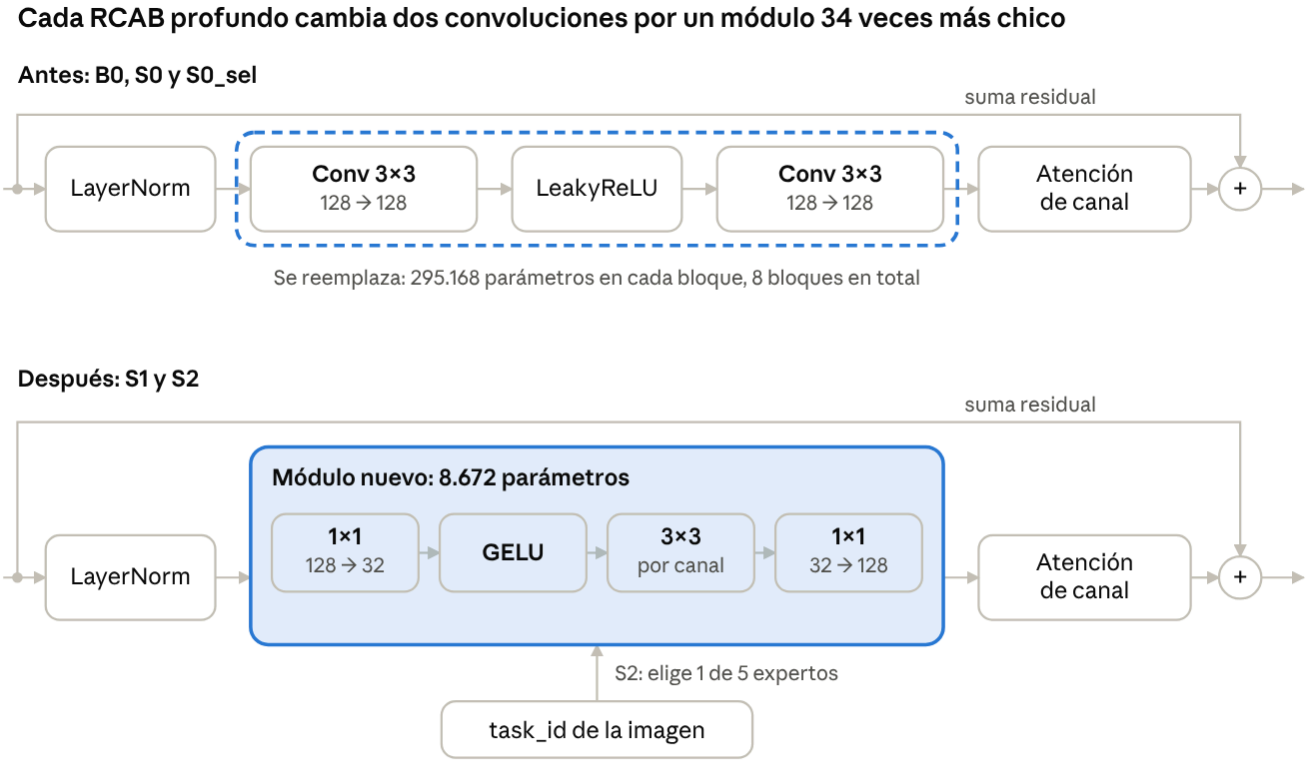
MAXIM S-2 tiene dos etapas. Cada una es una U-Net de tres niveles, numerados 0, 1 y 2, de 32, 64 y 128 canales, con un cuello de botella global. Los expertos de S2 están en el nivel más profundo, el 2, de las dos etapas y en la salida final.



Arquitectura de S2 · versión actualizada de la figura MAXIM+MoE de la tesis

A diferencia de la figura MAXIM+MoE original, no hay router: la etiqueta de la tarea elige el experto en cada lugar. El experto residual suma una corrección a la salida de MAXIM, en lugar de reconstruir la imagen desde x.

- **Antes:** en cada uno de los ocho lugares, dos convoluciones 3×3 de 128 a 128 canales, con 295.168 parámetros.
- **Después:** un módulo pequeño con cuello de botella. Proyecta de 128 a 32 canales, aplica GELU y una convolución 3×3 por canal, y vuelve a 128 canales. Tiene 8.672 parámetros, 34 veces menos. Al tener una sola convolución espacial, cada bloque ve un entorno de 3×3 píxeles en lugar de 5×5.
- **Módulo común o expertos.** El módulo nuevo puede ser uno solo, compartido por las cinco tareas. También puede ser un banco de cinco expertos, uno por tarea. En el banco se ejecuta sólo el experto de la tarea de cada imagen: los otros cuatro no se calculan.



S1 usa un solo módulo común a las cinco tareas. S2 tiene cinco copias, una por tarea, y ejecuta sólo la de la imagen.

Bloque RCAB del nivel profundo, antes y después · maxim/models/maxim.py y compression.py

La normalización, la atención de canal y la suma residual del RCAB no cambian. Sólo cambia lo que está entre ellas.

El resto de la red se mantuvo igual y congelado, incluidos los gMLP multi-eje, el cross-gating y los expertos residuales finales del shared.

Versiones comparadas

La comparación central es S2 contra S1. Tienen el mismo costo de ejecución y sólo difieren en si el módulo nuevo es común o especializado por tarea. Los sufijos _l12 y _l012 indican que el módulo nuevo reemplaza también los RCAB del nivel 1, o de los niveles 1 y 0; sin sufijo, sólo los del nivel 2.

Versión	Qué es	Parámetros
B0	Baseline, MAXIM sin expertos	14,18 M
S0	Shared original: calcula las cinco correcciones y se queda con la del experto de la tarea	14,27 M

Versión	Qué es	Parámetros
S0_sel	Shared con ejecución selectiva: calcula sólo el experto de la tarea. Mismos pesos y misma salida que S0	14,27 M
S1_d32	S0_sel con un módulo común de ancho 32 en lugar de las convoluciones del nivel 2	11,98 M
S2_d32	**S0_sel con cinco expertos de ancho 32, uno por tarea, en el nivel 2**	**12,26 M**
S1_d32_l12	S1_d32 con módulo común en niveles 1 y 2	11,43 M
S2_d32_l12	S2_d32 con expertos en niveles 1 y 2	11,85 M
S1_d32_l012	S1_d32_l12 con el módulo común en todos los niveles	11,30 M
S2_d32_l012	S2_d32_l12 con los expertos también en todos los niveles	11,80 M

En el benchmark de costo también medimos otras versiones como referencia:

- S1 y S2 con ancho 64.
- S2 calculando los cinco expertos, para ver cuánto cuesta no seleccionar.
- Tres límites teóricos: sin las convoluciones reemplazadas, sin cross-gating y sin gMLP multi-eje.
- B0 y S2 en bf16, y B0 con rematerialización para ahorrar memoria de entrenamiento.

Pruebas realizadas

Hicimos dos benchmarks de costo, dos adaptaciones con semillas distintas, la validación de cada una y un test final. Después probamos llevar los expertos a más niveles de la red, con cuatro adaptaciones más y una validación con intervalos. Con la decisión ya tomada, evaluamos esas versiones en test y medimos su costo en un benchmark aparte. Todas las corridas fueron en Colab con una GPU L4.

Fecha	Prueba	Qué se obtuvo
4/11	Test y benchmark de las versiones por niveles	En test, S2_d32_l12 queda 0,05 dB por debajo de S2_d32 y repite la pérdida en derain, −0,26 dB. Con 15,6 % menos FLOPs, la latencia baja sólo 2,3 %. Los modelos del 28/10 reproducen su test

Fecha	Prueba	Qué se obtuvo
3/11	Validación con intervalos de las versiones por niveles	La pérdida de S2_d32_l12 en derain, −0,32 dB con IC [−0,37, −0,26], queda entera fuera del criterio. En el promedio empata con S2_d32
30/10–3/11	Adaptación con expertos en los niveles 1 y 2, dos semillas	S2 iguala a la versión anterior en el promedio y duplica la reducción de FLOPs, pero pierde 0,3 dB en derain en las dos semillas. No cumple el criterio
28–29/10	Adaptación con expertos en los tres niveles	S2 queda 0,38 dB por debajo del shared, con dehaze −1,82 dB. No cumple el criterio
28/10	Validación con las dos semillas	S2 supera a S1 por 0,115 dB promediando las semillas, con el mismo patrón por tarea en las dos. La semilla 1 reproduce la validación del 21/10
28/10	Test final, 4.730 imágenes	S2 supera a S1 en las dos semillas y empata con el shared. Un primer intento, el 27/10, se cortó por falta de memoria antes de evaluar ningún modelo
23–25/10	Adaptación de S1 y S2, semilla 2	Mismo resultado que la semilla 1: S2 queda 0,118 dB por encima de S1 en validación
21/10	Validación de la semilla 1, 2.303 imágenes	S2 supera a S1 por 0,112 dB. bf16 pierde entre 0,67 y 0,90 dB
20/10	Adaptación de S1 y S2, semilla 1	Sin las convoluciones, el modelo cae a 30,05 dB. La adaptación recupera la calidad en pocas épocas
18/10	Benchmark v2: costo de las versiones comprimidas	Parámetros, FLOPs, latencia y memoria de todas las versiones
13/10	Benchmark v1: diagnóstico de costo de B0 y S0	El modelo está limitado por memoria y no por cálculo. Se eligió el bloque a reemplazar

Cómo se adaptaron S1 y S2:

- El shared original queda congelado y actúa como profesor.

- Sólo se entrenan los módulos nuevos, 5 épocas de 2.000 pasos.
- La pérdida combina la reconstrucción de la imagen limpia, la imitación de la salida del profesor y la imitación de las salidas de los bloques reemplazados.
- S1 y S2 ven exactamente los mismos datos en el mismo orden.
- La mejor época se elige en validación. El test se usó dos veces, siempre con lo que se iba a comparar fijado de antemano: el 28/10, S2 contra S1; el 4/11, las versiones por niveles, ya decididas con validación.

Reducción de costo

S2 tiene **1,92 M parámetros menos que el baseline, −13,5 %**, y 2,01 M menos que el shared, −14,1 %. Los FLOPs bajan 7,3 % frente al baseline. La latencia casi no cambia, porque el modelo está limitado por los accesos a memoria y no por el cálculo.

Versión	Parámetros	GFLOP a 256×256	Latencia a 256 (ms)	Latencia a 512 (ms)
B0	14,18 M	216,3	41,6	254,0
S0	14,27 M	229,2	43,9	263,2
S0_sel	14,27 M	218,9	42,2	256,3
S1_d32	11,98 M	200,5	41,1	252,8
S2_d32	**12,26 M**	**200,5**	**41,1**	**252,6**
S1_d32_l12	11,43 M	182,6	41,1 (−1,4 %)	251,4 (−2,4 %)
S2_d32_l12	11,85 M	182,6	40,8 (−2,3 %)	251,4 (−2,5 %)
S1_d32_l012	11,30 M	165,9	39,9 (−4,5 %)	251,6 (−2,4 %)
S2_d32_l012	11,80 M	165,9	40,0 (−4,2 %)	249,7 (−3,1 %)

Latencia: mediana en una GPU L4 con batch 1, en float32. FLOPs: conteo del programa antes de optimizar, igual para todas las versiones. Las filas hasta S2_d32 son del benchmark v2 del 18/10. Las versiones por niveles se midieron el 4/11 en otra corrida, junto con B0 y S2_d32. Entre paréntesis, su diferencia frente al B0 de esa misma corrida, que dio 41,7 y 257,7 ms. En esa corrida, S2_d32 quedó −0,3 % y −0,8 % frente a B0, dentro de la variación entre mediciones.

Lo que gana S2 frente al baseline B0:

- **Parámetros:** −13,5 % en total y −16,0 % de parámetros usados por imagen, porque cada imagen usa sólo un experto.

- **Memoria de pesos:** 49 MB en float32, contra 57 MB del baseline.
- **FLOPs:** −7,3 %.
- **Latencia:** −1,1 % a 256×256 y −0,5 % a 512×512.
- **Adaptación barata:** entrenar sólo los módulos nuevos cuesta 49 % menos tiempo por paso y 55 % menos memoria que un paso completo. Son 5,3 GiB contra 11,8 GiB.

Lo que cuestan los expertos frente al módulo común: 277 mil parámetros guardados más, el 2,3 % del modelo. En ejecución S1 y S2 cuestan lo mismo: elegir el experto no agrega tiempo. Calcular los cinco expertos en lugar de elegir uno agregaría entre 1,6 % y 2,4 % de latencia.

Otras palancas medidas, que no dependen de los expertos:

- **bf16:** baja la latencia entre 54 % y 64 %, pero pierde entre 0,67 y 0,90 dB de PSNR macro en validación. Casi toda la pérdida está en dehaze.
- **Rematerialización:** baja 81 % la memoria de entrenamiento, a cambio de 19 % más de tiempo por paso.
- **Dónde está el resto del costo:** los gMLP multi-eje y el cross-gating concentran el 63 % de los parámetros. Sin los gMLP, la latencia bajaría entre 33 % y 40 %.

Resultados de calidad

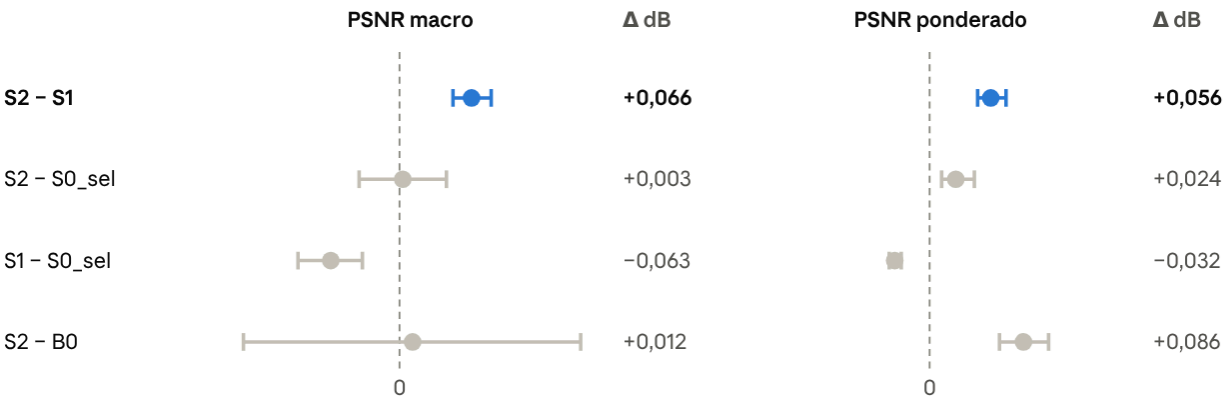
En test, **S2 supera a S1 por 0,066 dB de PSNR macro**, con un intervalo de confianza que excluye el cero, y empata con el shared. S1, con el mismo costo que S2, pierde 0,063 dB frente al shared.

Versión	PSNR macro (dB)	PSNR ponderado (dB)	SSIM macro
B0	28,127	27,248	0,8507
S0_sel	28,137	27,309	0,8496
S1_d32, promedio de 2 semillas	28,074	27,278	0,8495
S2_d32, promedio de 2 semillas	**28,140**	**27,334**	**0,8497**
S1_d32_l12, una semilla	27,872	27,172	0,8445
S2_d32_l12, promedio de 2 semillas	28,093	27,336	0,8478
S1_d32_l012, una semilla	27,526	27,004	0,8359
S2_d32_l012, una semilla	28,015	27,330	0,8459

Las versiones con el módulo nuevo en más niveles se decidieron sólo con validación y se evaluaron en test el 4/11, ya cerrada la decisión. Sus diferencias están en Expertos en más niveles.

S2 supera a S1 y empata con el shared en test

Diferencia de PSNR en test, en dB, con intervalo de confianza del 95 %. Promedio de las dos semillas.



A la derecha del 0 gana la primera versión. Si el intervalo no toca el 0, la diferencia es clara.

runs_logs/compresion_test_final · 4.730 imágenes de test, bootstrap pareado estratificado por tarea

- **Las dos semillas coinciden:** S2 − S1 da +0,059 dB en una y +0,073 dB en la otra.
- **Por tarea, S2 no pierde frente a S1 en ninguna.** Las ganancias son denoise +0,17 dB, derain +0,08, dehaze +0,06, deblur +0,03 y enhance 0,00.
- **En validación la ventaja de S2 sobre S1 era mayor,** +0,115 dB promediando las dos semillas, IC [+0,086, +0,154]. Es esperable, porque la mejor época se eligió en validación. Allí S2 incluso superaba al shared por 0,055 dB, pero en test empata. En cambio, la pérdida de S1 frente al shared es igual en los dos splits: −0,060 dB en validación y −0,063 en test.
- **El reparto por tarea depende del split, no de la semilla.** En validación, la ventaja de S2 sobre S1 viene sobre todo de dehaze, con +0,33 y +0,41 dB, y en denoise es apenas negativa; las dos semillas dan el mismo patrón. En test, en cambio, la mayor ganancia está en denoise. Lo que se mantiene en las cuatro combinaciones de split y semilla es que S2 supera a S1 en el promedio.
- **Frente al baseline, el intervalo macro es ancho por diferencias que ya tenía el shared.** En enhance pierde 0,37 dB frente al baseline y en dehaze gana entre 0,2 y 0,3 dB. La compresión no las introduce.

Expertos en más niveles

Después del test probamos llevar los mismos módulos a los bloques RCAB de los dos niveles menos profundos, el 0 y el 1, de 32 y 64 canales. Como antes, cada versión con expertos (S2) se compara con la misma versión con un módulo común (S1). Usamos el

mismo protocolo de adaptación y decidimos sólo con validación. Fijamos el criterio antes de correr: una versión es aceptable si queda a menos de 0,05 dB del shared en PSNR macro y ninguna tarea cae más de 0,10 dB.

Versión	Niveles con el módulo nuevo	Parámetros vs B0	GFLOP vs B0	Δ macro vs shared	Peor tarea vs shared	Cumple
S1_d32	2	−15,5 %	−7,3 %	−0,042 / −0,078	derain −0,14 / dehaze −0,27	no
S2_d32	**2**	**−13,5 %**	**−7,3 %**	**+0,070 / +0,041**	**derain −0,01 / −0,03**	**sí**
S1_d32_l12	1 y 2	−19,4 %	−15,6 %	−0,326	dehaze −0,91	no
S2_d32_l12	1 y 2	−16,4 %	−15,6 %	+0,080 / +0,059	derain −0,30 / −0,33	no
S1_d32_l012	0, 1 y 2	−20,3 %	−23,3 %	−1,125	dehaze −4,05	no
S2_d32_l012	0, 1 y 2	−16,8 %	−23,3 %	−0,378	dehaze −1,82	no

Validación, en dB, frente al shared S0_sel. Con dos valores: semilla 1 / semilla 2; S1_d32_l12 y las versiones de tres niveles se corrieron con una sola semilla. Cumple: Δ macro de −0,05 dB o más y ninguna tarea por debajo de −0,10 dB. Los costos absolutos están en la tabla de reducción de costo.

- **Con los niveles 1 y 2, S2 iguala a la versión anterior y duplica la reducción de FLOPs.** Promediando las dos semillas queda +0,014 dB por encima de S2_d32 en PSNR macro, con IC [−0,017, +0,055]: un empate, con −15,6 % de FLOPs en lugar de −7,3 %. Gana en deblur, dehaze y denoise, entre +0,08 y +0,17 dB, con intervalos que excluyen el cero.
- **Pero pierde unos 0,3 dB en derain, en las dos semillas, y por eso no cumple el criterio.** Frente al shared, derain queda en −0,32 dB con IC [−0,37, −0,26]: todo el intervalo está más allá del límite de −0,10, así que no es ruido. Seguir entrenando no lo corrige: derain se estanca en las dos últimas épocas.
- **Con los tres niveles la pérdida es mayor, sobre todo en dehaze.** Agregar el nivel 0 casi no ahorra parámetros: con 32 canales, un módulo de ancho 32 no comprime nada. Cada nivel afecta a una tarea distinta: el nivel 1 a derain y el nivel 0 a dehaze.
- **Cuanto más se comprime, más valen los expertos.** S2 supera al módulo común S1 por 0,11 dB con el nivel 2, 0,41 dB con los niveles 1 y 2, y 0,75 dB con los tres, en la semilla 1, siempre con intervalos que excluyen el cero. Con menos capacidad local, importa más que la corrección sea específica de cada tarea.
- **Son números de validación,** la misma con que se eligió cada época, así que son optimistas. Los intervalos son de bootstrap pareado, estratificado por tarea, sobre 2.303 imágenes.

Test y latencia

Con la decisión ya tomada, el 4/11 evaluamos estas versiones en test y medimos su latencia, todas en una misma corrida del benchmark.

Versión	Δ macro vs shared	Peor tarea vs shared	Latencia a 256 vs B0
S1_d32	−0,070 / −0,056	denoise −0,14 / dehaze −0,18	−1,0 %
S2_d32	−0,011 / +0,017	dehaze −0,07 / −0,12	−0,3 %
S1_d32_l12	−0,264	dehaze −0,70	−1,4 %
S2_d32_l12	−0,106 / +0,019	dehaze −0,41 / derain −0,26	−2,3 %
S1_d32_l012	−0,611	dehaze −1,56	−4,5 %
S2_d32_l012	−0,122	dehaze −0,46	−4,2 %

Test, 4.730 imágenes, en dB frente al shared S0_sel. Con dos valores: semilla 1 / semilla 2. Latencia: mediana a 256×256 en L4, frente al B0 de la misma corrida; la variación entre mediciones llega al 3,9 % en algunas versiones.

- **En test, S2_d32_l12 queda por debajo de S2_d32.** Promediando las semillas, la diferencia es −0,047 dB de PSNR macro, con IC [−0,085, −0,004], y −0,044 frente al shared, con IC [−0,109, +0,026]. En validación empataba con S2_d32.
- **La pérdida en derain se repite:** −0,26 dB en las dos semillas, con IC [−0,31, −0,22].
- **La ganancia en dehaze no se repite.** Era +0,33 dB en validación y es −0,24 en test, con IC [−0,39, −0,08], sobre todo por la semilla 1: −0,41 frente a −0,07. Las dos semillas difieren mucho en el macro, −0,106 y +0,019, así que con dos semillas el promedio de test todavía es incierto.
- **La ventaja de los expertos también crece en test.** S2 supera a S1 por 0,06 dB con el nivel 2, 0,16 con los niveles 1 y 2, y 0,49 con los tres, en la semilla 1.
- **Los FLOPs casi no se convierten en tiempo.** Con los niveles 1 y 2, −15,6 % de FLOPs da −2,3 % de latencia a 256 y −2,5 % a 512. Con los tres niveles, −23,3 % da −4,2 % y −3,1 %. Después de compilar, estas versiones hacen algo más de cálculo y de accesos a memoria que B0, y lanzan más kernels: los módulos nuevos son operaciones pequeñas en un modelo limitado por memoria.
- **El test no cambia la decisión.** S2_d32 sigue siendo la versión principal y S2_d32_l12 el punto de compromiso, ahora con sus números de test. En test sólo S2_d32 con la semilla 1 cumpliría el criterio: con la semilla 2, dehaze queda en −0,12 dB, como ya ocurría el 28/10.

Conclusiones y próximo paso

Los expertos por tarea permiten achicar MAXIM un 13,5 % sin perder calidad. Un módulo común del mismo costo no lo logra.

1. **La especialización es lo que conserva la calidad.** S1 y S2 tienen el mismo costo de ejecución, y sólo S2 iguala al shared.
2. **El ahorro es de tamaño y de operaciones, no de tiempo.** Parámetros −13,5 % y FLOPs −7,3 %, con latencia prácticamente igual. Incluso con los niveles 1 y 2, −15,6 % de FLOPs da sólo −2,3 % de latencia.
3. **Especializar casi no cuesta:** 2,3 % más de parámetros guardados que el módulo común, y el mismo tiempo de ejecución.
4. **La adaptación es barata:** se entrenan sólo los módulos nuevos, con la mitad de tiempo y memoria por paso.
5. **Llevar los expertos a más niveles es un compromiso, no un ahorro gratis.** Con los niveles 1 y 2, S2 baja los FLOPs 15,6 % y la latencia 2,3 %, pero pierde entre 0,26 y 0,32 dB en derain, en validación y en test. En test queda además 0,05 dB por debajo de S2_d32 en el promedio. Con menos capacidad, la ventaja de los expertos sobre el módulo común crece.

Estado: los experimentos de esta fase están cerrados. La versión principal es S2_d32, la única que no pierde calidad en ninguna tarea en validación. S2_d32_l12 se presenta como punto de compromiso, con sus números de test. Una convolución por canal de 5×5, que recuperaría el entorno de 5×5 de las dos convoluciones originales, queda como trabajo futuro: podría explicar parte de la pérdida en derain.

Otro paso posible: usar el modelo sin conocer la tarea. Hoy S2 necesita el `task_id` de cada imagen. Calcular los cinco expertos no lo reemplaza: igual hay que elegir uno, y promediarlos aplicaría correcciones de otras degradaciones.

La propuesta es un clasificador liviano del tipo de degradación, entrenado aparte con S2 congelado. Predice la tarea y S2 sigue ejecutando un solo experto. Se evalúa comparando S2 con la tarea predicha contra S2 con la tarea real: la diferencia es lo que cuestan los errores del clasificador. Conviene probarlo también con imágenes de otras fuentes, para descartar que aprenda atajos del dataset.

Comprimir los gMLP multi-eje y el cross-gating daría más ahorro, porque concentran el 63 % de los parámetros, pero es un diseño nuevo y más riesgoso. Queda como trabajo futuro.