

Restauración de imágenes con MAXIM y Mixture of Experts

Matías Ariel Murat

*Facultad de Matemática, Astronomía, Física y Computación,
Universidad Nacional de Córdoba, Ciudad Universitaria, 5000 Córdoba, Argentina*

Este trabajo aborda la restauración de imágenes mediante una variante de MAXIM (Multi-Axis MLP) con un esquema de Mixture of Experts (MoE), que combina un backbone compartido con un ruteador que pondera dinámicamente un conjunto de cabezas expertas de reconstrucción, buscando especialización sin duplicar el costo de las etapas profundas. Sobre un conjunto unificado de cinco tareas, las versiones de MAXIM sin MoE alcanzan entre 23,1 y 25,5 dB de PSNR de validación —incluida una de idéntica escala e inicialización que la propuesta, que llega a 24,8 dB—, mientras que la variante MAXIM+MoE se estanca en torno a 12,7 dB con un ruteador que colapsa a un régimen prácticamente uniforme. Analizamos las causas —la pérdida de la supervisión profunda multi-escala de MAXIM, la baja capacidad de los expertos y una regularización que premia el ruteo uniforme— y derivamos líneas concretas de mejora. El resultado, negativo pero informativo, delimita las condiciones bajo las cuales la especialización tardía por expertos podría aportar valor en restauración de imágenes.

I. INTRODUCCIÓN

La restauración de imágenes es un problema central en visión por computadora de bajo nivel. En la práctica, las imágenes pueden verse degradadas por ruido, desenfoque, baja iluminación u otros factores, y cada tipo de degradación suele requerir estrategias de reconstrucción con sesgos diferentes. En este contexto, un único camino de procesamiento puede resultar limitado cuando se busca robustez frente a distribuciones heterogéneas.

MAXIM [1] constituye una alternativa relevante dentro de las arquitecturas recientes para restauración de imágenes, ya que combina operaciones locales y globales con un diseño completamente convolucional. Sin embargo, en su formulación estándar, el modelo mantiene un flujo de cómputo uniforme para todas las entradas. Esta característica simplifica el diseño, pero reduce su capacidad de especialización frente a escenarios diversos.

Para abordar ese punto, en este trabajo se propone integrar el paradigma Mixture of Experts (MoE) [2, 3] sobre MAXIM. La idea principal es mantener un backbone compartido para preservar eficiencia y, sobre la representación latente obtenida, aplicar un mecanismo de ruteo que pondere para cada entrada un conjunto de expertos de salida especializados.

Los objetivos de este trabajo son:

- Diseñar una variante MAXIM+MoE compatible con restricciones de memoria y entrenamiento.
- Definir un protocolo experimental claro para evaluar calidad de reconstrucción y costo computacional.
- Analizar, mediante resultados cuantitativos y el diagnóstico del ruteador, en qué medida la especialización por expertos aporta frente a una versión sin MoE.

La organización del documento es la siguiente. En la Sección II se presentan los fundamentos teóricos de MAXIM y de MoE. En la Sección III se detalla la metodología implementada: arquitectura, datos, protocolo de entrenamiento y métricas. La Sección IV reporta los resultados cuantitativos de las cuatro configuraciones entrenadas y el análisis del ruteador. Las Secciones V y VI discuten los hallazgos y presentan las conclusiones, y la Sección VII delinea el trabajo futuro.

II. TEORÍA

A. MAXIM como arquitectura base

MAXIM (Multi-Axis MLP) es una arquitectura orientada a tareas de restauración de imágenes. Su diseño general sigue una estructura tipo U, donde las conexiones skip permiten combinar información de bajo y alto nivel. A diferencia de enfoques puramente convolucionales, MAXIM incorpora bloques MLP con mecanismos de compuerta que capturan interacciones de largo alcance.

La arquitectura se apoya principalmente en dos módulos. El primero es el bloque *multi-axis gated MLP*, que permite modelar interacciones locales y globales entre elementos visuales a través de compuertas aplicadas sobre distintos ejes de la representación. El segundo es el bloque de compuertas cruzadas, propuesto como una alternativa basada en MLP a mecanismos de atención cruzada. En conjunto, estos módulos permiten incorporar contexto global sin abandonar una estructura eficiente para el procesamiento de imágenes.

Una propiedad importante de esta arquitectura es que mantiene una naturaleza completamente convolucional en el flujo de entrada y salida. Esto permite procesar imágenes de tamaño variable sin rediseñar el modelo para cada resolución. Además, MAXIM expresa campos re-

ceptivos globales sobre imágenes arbitrariamente grandes con un costo que escala linealmente con el tamaño de la entrada, evitando el crecimiento cuadrático típico de mecanismos de atención global directa.

El diseño también integra varias ideas frecuentes en visión de bajo nivel, como aprendizaje residual, conexiones densas, estructuras jerárquicas, procesamiento en múltiples etapas y mecanismos de atención o compuerta. Su combinación de bloques locales convolucionales y bloques globales basados en MLP logran un balance útil entre preservación de detalle fino y uso de contexto amplio, logrando buen desempeño sin depender necesariamente de preentrenamiento a gran escala.

MAXIM está implementado usando Flax, una librería Python de redes neuronales construida sobre JAX, una librería de computación numérica de alto rendimiento. Flax/JAX permiten usar diferenciación automática o algorítmica, más eficiente que los métodos clásicos de diferenciación numérica o simbólica. Otra ventaja de JAX es que permite la compilación JIT (*just-in-time*), una técnica que combina interpretación y compilación. Consiste en compilar y optimizar dinámicamente los métodos más usados durante la ejecución, combinando ventajas como la velocidad del código compilado y la flexibilidad del interpretado.

B. Paradigma Mixture of Experts

Mixture of Experts (MoE) es un paradigma de modelado en el cual varios submódulos especialistas (expertos) colaboran bajo un mecanismo de ruteo. El ruteador recibe una representación de la entrada y estima qué experto, o conjunto reducido de expertos, es más apropiado para producir la salida.

La motivación principal de MoE es aumentar la capacidad de representación sin activar todos los parámetros para cada muestra. De este modo, el sistema puede adaptarse mejor a datos heterogéneos, manteniendo controlado el costo computacional efectivo por inferencia.

El ruteo admite distintas variantes. En el ruteo *disperso* (*sparse*) se selecciona únicamente el experto de mayor peso (top-1) o los dos de mayor peso (top-2), de modo que solo una fracción de los expertos se evalúa por muestra [3, 4]. En el ruteo *denso* o *suave*, en cambio, todos los expertos se evalúan y la salida es una combinación convexa de sus predicciones, ponderada por una distribución *softmax* sobre los pesos de compuerta. La variante densa es más simple y diferenciable de extremo a extremo, pero no reduce el cómputo y, como se verá, es más propensa a soluciones de ruteo poco discriminativas.

En el contexto de restauración de imágenes, esta idea resulta relevante porque un único modelo puede recibir entradas afectadas por degradaciones distintas, como ruido, desenfoco, baja iluminación o compresiones con diferentes características. Un camino de cómputo com-

partido debe representar todos esos casos con los mismos parámetros activos, mientras que un esquema MoE permite dividir implícitamente el problema en subconjuntos y asignar expertos a patrones de degradación o regiones del espacio de datos.

C. Integración MAXIM+MoE propuesta

En este trabajo no se replica el backbone completo de MAXIM para cada experto. En cambio, se usa un único extractor compartido de características profundas y se aplica la especialización en la etapa de reconstrucción final. En términos conceptuales, dado un mapa de características $f_\theta(x)$, la salida se modela como:

$$\hat{y} = \sum_{k=1}^K p_k(x) E_k(f_\theta(x)), \quad (1)$$

donde E_k representa al experto k y $p_k(x)$ es el peso asignado por el ruteador para la entrada x .

Esta formulación habilita un gradiente de especialización entre expertos sin multiplicar el costo de las capas profundas de MAXIM. La decisión responde a una restricción práctica del proyecto: la replicación completa de bloques globales incrementa fuertemente el consumo de memoria y dificulta el entrenamiento estable con recursos limitados.

En este esquema, los expertos no procesan directamente la imagen degradada ni intervienen en las primeras etapas de extracción de características. Cada experto funciona como una cabeza de salida especializada que opera sobre la representación latente producida por MAXIM. Por lo tanto, el ruteador puede interpretarse como un selector de hipótesis de reconstrucción: a partir de las características globales de la entrada, pondera las salidas expertas que mejor se ajustan al caso observado.

Este enfoque conserva las ventajas centrales de MAXIM, como su carácter completamente convolucional y su capacidad para operar sobre resoluciones arbitrarias, pero introduce especialización con un incremento marginal respecto del costo del backbone. La propuesta puede verse como un compromiso entre capacidad y eficiencia: la especialización ocurre en una etapa tardía, aunque sobre representaciones suficientemente ricas para capturar variaciones complejas en la reconstrucción.

D. Consideraciones de entrenamiento

La integración de MoE introduce desafíos específicos. El más conocido es el *colapso del ruteador*: el sistema puede converger a usar siempre el mismo experto, o bien al extremo opuesto, repartir la carga de forma idéntica entre todos los expertos sin diferenciarlos. Para mitigar el primer caso es habitual añadir un término de *bal-*

ance de carga que penaliza distribuciones de uso muy desiguales [3, 4], y un término de *entropía* que regula cuán concentrada o dispersa es la distribución de computa. Estos términos deben calibrarse con cuidado: una regularización demasiado fuerte hacia el balance empuja precisamente hacia el segundo modo de colapso, en el que el ruteo se vuelve uniforme y deja de aportar especialización.

Por ese motivo, el protocolo metodológico contempla estos criterios de balance y un monitoreo explícito de la utilización por experto. Con este marco teórico, la siguiente sección describe el diseño experimental adoptado para implementar y evaluar la variante MAXIM+MoE.

III. METODOLOGÍA

A. Diseño del modelo

La arquitectura implementada se compone de tres partes:

- un backbone MAXIM compartido, encargado de extraer representaciones latentes a partir de la imagen degradada;
- un módulo de ruteo, que a partir de la imagen de entrada estima una distribución de pesos sobre los expertos;
- un conjunto de K cabezas expertas de salida, cada una encargada de la proyección desde la representación latente hacia la imagen restaurada.

Concretamente, el backbone produce el mapa de características de la última etapa del decodificador a resolución completa, $f_\theta(x)$. El ruteador es una red liviana independiente —un pequeño backbone de convoluciones separables en profundidad seguido de un perceptrón multicapa— que emite K logits; sobre ellos se aplica *softmax* con una temperatura de 1,5 durante el entrenamiento y de 1,0 en evaluación. Cada experto E_k es una única convolución 3×3 que mapea $f_\theta(x)$ a tres canales RGB. La salida es la combinación convexa de las cabezas (ruteo denso), a la que se suma la entrada como conexión residual,

$$\hat{y} = x + \sum_{k=1}^K p_k(x) E_k(f_\theta(x)). \quad (2)$$

Se utilizan $K = 5$ expertos, en correspondencia nominal con las cinco tareas consideradas. Este diseño prioriza la eficiencia de memoria: los expertos añaden una cantidad de parámetros despreciable frente al backbone, de modo que la especialización se introduce sin duplicar las etapas más costosas del modelo.

B. Datos y tareas

El estudio se realiza sobre un conjunto unificado de cinco tareas de restauración: *deblurring* (eliminación de desenfoque), *dehazing* (eliminación de neblina), *denoising* (eliminación de ruido), *deraining* (eliminación de lluvia) y *enhancement* (realce de imágenes en baja iluminación). Cada tarea se organiza en una carpeta con pares de imagen degradada y objetivo (*ground truth*), tomados de *benchmarks* estándar de restauración; en particular, las tareas de *deblurring* y *enhancement* se asocian a Go-Pro [5] y LOL [6], que son además los conjuntos de los *checkpoints* preentrenados de MAXIM empleados como punto de partida. Las tareas de *denoising*, *dehazing* y *deraining* se representan con conjuntos de la misma familia de *benchmarks* [7–9].

Durante el entrenamiento, las muestras se extraen de las cinco tareas con un esquema de muestreo *uniforme* (cada tarea contribuye en igual proporción por época). En validación se emplea un muestreo *proporcional* al tamaño de cada conjunto. Tanto en entrenamiento como en validación se opera sobre parches de 256×256 píxeles —extraídos de forma aleatoria— con normalización al rango $[0, 1]$; en entrenamiento se aplican además aumentos de datos por reflejos y rotaciones de 90° . La restricción a parches en validación responde a limitaciones de memoria del entorno de cómputo.

C. Protocolo de entrenamiento

Se entrenaron cuatro configuraciones que comparten infraestructura, hiperparámetros base y definición de las métricas. Tres de ellas operan sobre la mezcla completa de las cinco tareas y comparten exactamente el mismo conjunto de validación, por lo que son directamente comparables entre sí; la cuarta (mono-tarea) se valida sobre una sola tarea y se incluye como referencia adicional:

- **MAXIM mono-tarea:** el modelo base (variante S-2), sin MoE, entrenado desde inicialización aleatoria sobre una única tarea de restauración (realce);
- **MAXIM multi-tarea (pre-entrenado):** el modelo base (variante S-3), sin MoE, entrenado sobre la mezcla de las cinco tareas e inicializado desde un *checkpoint* preentrenado de MAXIM (Enhancement/LOL);
- **MAXIM multi-tarea (desde cero):** el modelo base sin MoE en la variante S-2, entrenado sobre la misma mezcla pero desde inicialización aleatoria; comparte escala e inicialización con la variante MoE y constituye la comparación más justa;
- **MAXIM+MoE:** la variante propuesta, cuyo backbone es la variante S-2, entrenada sobre la

misma mezcla de cinco tareas y desde inicialización aleatoria.

Las variantes S-2 y S-3 de MAXIM se diferencian en el número de etapas de procesamiento (dos y tres, respectivamente): a mayor número de etapas, mayor capacidad del modelo y más puntos de supervisión. Conviene notar que la variante MoE y la versión multi-tarea desde cero comparten escala (S-2), inicialización aleatoria y conjunto de datos: su única diferencia es el esquema de expertos con supervisión de una sola escala, lo que permite aislar con precisión el efecto de la propuesta.

La función de pérdida del modelo base es un error absoluto medio (L1) con *supervisión profunda*: se evalúa en las salidas de todas las etapas y escalas de MAXIM, con un peso $0,5^{(S-1-i)}$ para la escala i de un total de $S = 3$ escalas de supervisión. En la variante MoE, en cambio, el camino de cómputo produce una única salida a resolución completa, por lo que la pérdida de reconstrucción es un L1 de una sola escala. A esta se suma la regularización del ruteador,

$$\mathcal{L} = \mathcal{L}_{L1} - \lambda_{\text{ent}} \mathcal{H}(p) + \lambda_{\text{bal}} \mathcal{B}(p), \quad (3)$$

donde $\mathcal{H}(p)$ es la entropía media de la distribución de compuerta, $\mathcal{B}(p) = K \sum_k \bar{p}_k^2$ es el término de balance de carga (mínimo, igual a 1, cuando el uso medio $\bar{p}_k$ es uniforme), $\lambda_{\text{ent}} = 10^{-3}$ y $\lambda_{\text{bal}} = 10^{-2}$.

En todas las configuraciones se utilizó el optimizador AdamW [10] con tasa de aprendizaje base 2×10^{-4} , *weight decay* 10^{-4} , recorte de gradiente por norma global a 1,0, un calentamiento (*warmup*) lineal de 3 épocas y posterior decaimiento por coseno. El tamaño de *batch* fue de 2 y cada época abarcó 2000 pasos. Todas las configuraciones se entrenaron con un presupuesto de 30 épocas, fijado para mantener una comparación justa entre modelos; la variante MoE se monitoreó además hasta más de 60 épocas, lo que permitió verificar que su estancamiento no se debía a un presupuesto insuficiente. Se conservó el *checkpoint* con mejor PSNR de validación.

D. Métricas de evaluación

La calidad de reconstrucción se cuantifica con la *PSNR* (*Peak Signal-to-Noise Ratio*) sobre el conjunto de validación, calculada de manera idéntica en las cuatro configuraciones a partir del error cuadrático medio en escala [0, 255],

$$\text{PSNR} = 20 \log_{10} \left(\frac{255}{\sqrt{\text{MSE}}} \right). \quad (4)$$

Como métrica perceptual complementaria se reporta la *SSIM* (*Structural Similarity Index*) [11], que evalúa la similitud estructural local entre la reconstrucción y la

referencia y resulta más sensible que la PSNR a la calidad percibida; se incluye además la pérdida L1 de validación como medida de fidelidad. Una métrica perceptual basada en redes, como LPIPS [12], podría incorporarse en un análisis posterior. Para la variante MoE se monitorean, adicionalmente, métricas específicas del ruteador: la entropía de la distribución de compuerta, el término de balance de carga y el uso medio por experto, que permiten diagnosticar la aparición de colapso del ruteo. El análisis se complementa con una inspección cualitativa de reconstrucciones representativas.

E. Implementación y recursos

La implementación se realiza en Python sobre el ecosistema JAX/Flax [13, 14], aprovechando la compilación JIT y la diferenciación automática. Para acotar el consumo de memoria en la variante MoE se recurrió al *gradient checkpointing* (recomputación de activaciones en el paso hacia atrás), lo que permitió entrenar con el *batch* reducido indicado. Los entrenamientos se ejecutaron en una única GPU en un entorno de tipo Colab; esta restricción de memoria es la que motiva tanto el tamaño de *batch* de 2 como el diseño de expertos de salida en lugar de la replicación de bloques internos del backbone.

IV. RESULTADOS

Se reportan los resultados de las cuatro configuraciones descritas en la metodología, todas entrenadas y evaluadas con el mismo protocolo. El análisis se centra en la PSNR de validación, en la dinámica de entrenamiento de la variante MoE y en el comportamiento de su ruteador.

A. Resultados cuantitativos

La Tabla I resume el desempeño de las cuatro configuraciones, y la Fig. 1 muestra la evolución de la PSNR de validación a lo largo del entrenamiento. Las tres versiones sin MoE convergen al rango esperado para MAXIM: la multi-tarea pre-entrenada (S-3) alcanza 25,5 dB y la multi-tarea desde cero (S-2) llega a 24,8 dB, muy cerca de aquella pese a partir de pesos aleatorios y de una escala menor; la mono-tarea llega a 23,1 dB con una curva más ruidosa pero claramente ascendente.

La variante MAXIM+MoE presenta un comportamiento marcadamente distinto. Tras una mejora inicial muy rápida durante las primeras tres épocas —en las que pasa de $\sim 10,5$ a $\sim 12,3$ dB—, la PSNR de validación se estanca y oscila en torno a 12,5–12,7 dB sin progreso apreciable. El mejor *checkpoint* alcanza 12,7 dB. La comparación decisiva es con la versión multi-tarea desde cero:




FIG. 1. Evolución de la PSNR de validación durante el entrenamiento, para un presupuesto común de 30 épocas. Las tres versiones de MAXIM sin MoE —multi-tarea pre-entrenada (S-3), multi-tarea desde cero (S-2) y mono-tarea (S-2)— mejoran de forma sostenida y se agrupan por encima de 23 dB, mientras que la variante MAXIM+MoE se estanca tempranamente en torno a 12,7 dB. La comparación más justa es entre MAXIM+MoE y la multi-tarea desde cero, que comparten escala e inicialización. La curva mono-tarea comienza en la época 6 por el rango disponible en el registro de entrenamiento.

con idéntica escala (S-2), idéntica inicialización aleatoria, el mismo conjunto de entrenamiento y validación y el mismo presupuesto de 30 épocas, esa versión sin MoE alcanza 24,8 dB, es decir, unos 12 dB por encima. Prolongar el entrenamiento no modificó su estancamiento, lo que descarta un presupuesto de cómputo insuficiente.

TABLE I. Comparación cuantitativa sobre el conjunto de validación (parches de 256×256). Se reporta la mejor PSNR alcanzada, la SSIM asociada y la pérdida L1 de validación. “Escala” indica la variante de MAXIM (S-2 o S-3, según el número de etapas); “Inic.” la inicialización (aleatoria o desde *checkpoint* preentrenado) y “Sup.” el tipo de supervisión (multi-escala o de una sola escala). Los valores de SSIM, marcados con “—”, se obtienen ejecutando el *script* de evaluación `eval_metrics.py` sobre los *checkpoints* guardados.

Modelo	Escala	Inic.	Sup.	PSNR (dB)	SSIM
MAXIM mono-tarea	S-2	aleat.	multi	23,1	—
MAXIM multi-tarea	S-3	preentr.	multi	25,5	—
MAXIM multi-tarea	S-2	aleat.	multi	24,8	—
MAXIM+MoE	S-2	aleat.	simple	12,7	—

B. Dinámica de entrenamiento y comportamiento del ruteador

La Fig. 2 examina con mayor detalle la corrida de MAXIM+MoE. El panel (a) confirma que tanto la PSNR de entrenamiento como la de validación se estabilizan rápidamente cerca de 12,5–13 dB y permanecen allí durante toda la corrida; la pequeña oscilación periódica refleja la rotación entre las cinco tareas a lo largo de cada época. No se observa sobreajuste —las curvas de entrenamiento y validación permanecen muy próximas—, sino un estancamiento conjunto: el modelo deja de aprender, no memoriza.

El panel (b) revela la causa central. La entropía de la distribución de compuerta asciende casi de inmediato hasta su valor máximo, $\ln K \approx 1,609$ nats, y allí se mantiene; en paralelo, el término de balance de carga cae a su mínimo, 1,0. En conjunto, ambos indicadores describen un ruteador que reparte su peso de forma prácticamente uniforme entre los cinco expertos (un uso medio de 0,2 por experto, constante a lo largo de todo el entrenamiento). Es decir, el ruteador no llega a discriminar entre tareas ni tipos de degradación: la “mezcla de expertos” degenera en un promedio uniforme de cinco cabezas casi idénticas, equivalente en la práctica a una única cabeza de salida lineal.

Este patrón es coherente con la regularización empleada: tanto el premio a la entropía como la penalización del desbalance tienen su óptimo en la distribución uniforme, de modo que ambos términos empujan al ruteador hacia el mismo punto. Al no existir una señal que incentive la especialización —por ejemplo, una supervisión explícita de la tarea sobre el ruteador— y al ser el ruteo denso, la solución de mínimo esfuerzo consiste en igualar los pesos. El análisis de especialización por tipo de degradación, previsto inicialmente, pierde sentido en este escenario: sin asignaciones diferenciadas no emergen expertos asociados a degradaciones específicas.

C. Resultados cualitativos

La Fig. 3 contrasta reconstrucciones sobre muestras representativas de validación, ordenadas en columnas: la entrada degradada, la salida del modelo base multi-tarea, la de la variante MAXIM+MoE y la imagen de referencia. La comparación visual es consistente con la brecha cuantitativa de la Tabla I: el modelo base recupera estructura y contraste de forma fiel, mientras que la variante MoE entrega reconstrucciones marcadamente más pobres, con pérdida de detalle fino y un aspecto suavizado. Este comportamiento es el esperable de un ruteador que promedia de manera uniforme cinco cabezas equivalentes, en lugar de seleccionar una hipótesis de reconstrucción especializada para cada entrada.

El modelo mono-tarea se omite de la Fig. 3 porque,




FIG. 2. Diagnóstico de la variante MAXIM+MoE a lo largo de 62 épocas. (a) La PSNR de entrenamiento y validación se estancan en torno a 12,5–13 dB. (b) La entropía del ruteador (naranja) satura en su máximo $\ln K$ (línea punteada gris) y el balance de carga (verde) cae a su mínimo 1,0; el ruteo colapsa a un régimen uniforme y no especializado.

al estar especializado únicamente en la tarea *enhance*, su reconstrucción carece de sentido sobre las demás degradaciones. Para una comparación justa, la Fig. 4 restringe el contraste a esa tarea e incorpora su salida junto a las del modelo multi-tarea y la variante MAXIM+MoE. Sobre su tarea de entrenamiento, el especialista mono-tarea produce una reconstrucción al nivel del modelo multi-tarea, mientras que la variante MoE conserva el deterioro observado en el resto de las tareas.

V. DISCUSIÓN

Los resultados indican que, en la configuración evaluada, la variante MAXIM+MoE no mejora a la versión sin MoE; por el contrario, queda muy por debajo de todas las referencias. La comparación clave es con la versión multi-tarea entrenada desde cero, diseñada precisamente para eliminar factores de confusión: comparte con la variante MoE la escala del backbone (S-2), la inicialización aleatoria, el conjunto de entrenamiento y validación y el presupuesto de 30 épocas. Su única diferencia es el esquema de expertos con supervisión de una sola escala. Como esa versión alcanza 24,8 dB frente a los 12,7 dB del MoE, la brecha no puede atribuirse ni al preentrenamiento ni al tamaño del modelo: el cuello de botella está en el propio diseño y entrenamiento de la variante MoE.

El análisis del ruteador (Fig. 2) apunta a un *colapso hacia el ruteo uniforme*. Identificamos tres factores, todos propios de la variante MoE, que explican el comportamiento observado:

1. Regularización que premia la uniformidad.

El término de entropía (maximizado) y el de bal-

ance de carga (que es mínimo en la distribución uniforme) tienen su óptimo en el mismo punto. En ausencia de una señal que favorezca la concentración del ruteo, ambos términos arrastran al ruteador hacia pesos iguales, que es exactamente el régimen no especializado que se buscaba evitar.

2. Pérdida de la supervisión profunda de MAXIM.

El modelo base se entrena con supervisión multi-etapa y multi-escala, un ingrediente central de MAXIM. La variante MoE descarta esa estructura: toma solo las características finales del backbone y produce una única salida con pérdida de una sola escala. Sin esa supervisión intermedia, el backbone carece de las señales de gradiente que hacen converger a MAXIM.

3. Capacidad insuficiente de los expertos.

Cada experto es una sola convolución 3×3 . Aun si el ruteo discriminara correctamente, una proyección lineal de las características compartidas difícilmente puede representar reconstrucciones específicas por tarea. El presupuesto de especialización es, sencillamente, demasiado pequeño.

Descartamos, en cambio, que el problema provenga de las condiciones compartidas de entrenamiento — inicialización aleatoria y *batch* de tamaño 2 —, ya que la versión multi-tarea desde cero opera bajo esas mismas condiciones y sí converge. En cuanto al costo computacional, los expertos añaden una cantidad de parámetros despreciable, por lo que el sobre costo de la propuesta sobre el backbone es marginal. El problema, entonces, no es de eficiencia sino de eficacia: la especialización no llegó a materializarse. La decisión metodológica de mayor impacto fue concentrar toda la especialización en una




FIG. 3. Comparación cualitativa sobre muestras de validación de distintas tareas. De izquierda a derecha: entrada degradada, MAXIM multi-tarea, MAXIM+MoE e imagen de referencia. La figura se genera con el *script eval_metrics.py* a partir de los *checkpoints* guardados.



FIG. 4. Comparación cualitativa sobre la tarea *enhance*, la única en la que el modelo mono-tarea es directamente comparable. De izquierda a derecha: entrada degradada, MAXIM mono-tarea, MAXIM multi-tarea, MAXIM+MoE e imagen de referencia. La figura se genera con el *script eval_metrics.py* a partir de los *checkpoints* guardados.

etapa de salida mínima y, simultáneamente, abandonar la supervisión profunda que sostiene el entrenamiento de MAXIM.

Como subproducto, el trabajo deja líneas base sólidas y reproducibles: versiones multi-tarea de MAXIM que alcanzan entre 24,8 y 25,5 dB sobre la mezcla de cinco tareas —con y sin preentrenamiento— y una versión mono-tarea de referencia. Todas resultan útiles como punto de comparación para futuras variantes.

VI. CONCLUSIONES

El objetivo general de este trabajo fue evaluar si dotar a MAXIM de un esquema de Mixture of Experts en la etapa de reconstrucción aporta frente a una versión sin MoE. La evidencia experimental responde de forma negativa para la configuración estudiada: la variante MAXIM+MoE se estanca alrededor de 12,7 dB de PSNR de validación, frente a los 23,1–25,5 dB de las versiones sin MoE; en particular, una versión sin MoE de idéntica escala e inicialización alcanza 24,8 dB, lo que aísla el problema en el diseño de la propuesta y no en factores de confusión.

El hallazgo principal no es, sin embargo, la mera diferencia de PSNR, sino su explicación. El ruteador converge a un régimen prácticamente uniforme —entropía en su máximo $\ln K$ y balance de carga en su mínimo—, de modo que la mezcla de expertos degenera en un promedio de cabezas equivalentes y la especialización buscada nunca emerge. Este colapso es atribuible a la combinación de una regularización que premia la uniformidad, la pérdida de la supervisión profunda multi-escala de MAXIM, una capacidad de expertos demasiado baja y condiciones de optimización restrictivas.

El alcance del modelo implementado es, por lo tanto, limitado: tal como está formulado, el esquema de expertos de salida no aprovecha el potencial de la idea de especialización. No obstante, el trabajo cumple un propósito de delimitación: identifica con precisión qué condiciones impiden que la propuesta funcione y, con ello, qué habría que cambiar para que la especialización tardía por expertos sea viable en restauración de imágenes. Las líneas base entrenadas como referencia constituyen, además, un aporte concreto y reutilizable.

VII. TRABAJO FUTURO

Las causas identificadas sugieren intervenciones directas para una próxima iteración:

- **Preservar la supervisión profunda.** Conservar las salidas multi-etapa y multi-escala de MAXIM (o aplicar la mezcla de expertos sobre cada escala supervisada), de modo que el backbone reciba las señales de gradiente que necesita para converger.
- **Inicializar desde pesos preentrenados.** Partir del *backbone* preentrenado de MAXIM, como en la línea base multi-tarea, y reservar el entrenamiento desde cero solo para el ruteador y los expertos.
- **Replantear la regularización del ruteo.** Reducir o eliminar el premio a la entropía, calibrar el balance de carga para evitar que domine la pérdida, y considerar una supervisión explícita de la tarea

sobre el ruteador o un ruteo disperso (top-1/top-2) que fuerce decisiones discriminativas [3, 4].

- **Aumentar la capacidad de los expertos.**
Reemplazar la convolución única por cabezas con varias capas o bloques residuales, de modo que cada experto pueda representar reconstrucciones realmente distintas; y explorar la incorporación de expertos en etapas internas del backbone.
- **Mejorar las condiciones de optimización.**
Emplear acumulación de gradiente o *hardware* con más memoria para entrenar con *batches* efectivos mayores, y extender la evaluación con métricas perceptuales (SSIM, LPIPS) y a resolución completa.

VIII. AGRADECIMIENTOS

MAM agradece a la UNC, en especial a los profesores Juan Ignacio Perotti, Francisco Tamarit y Benjamín Marcolongo por su esfuerzo y paciencia para dictar el curso de *Redes Neuronales*.

-
- [1] Z. Tu, H. Talebi, H. Zhang, F. Yang, P. Milanfar, A. Bovik, and Y. Li, *MAXIM: Multi-Axis MLP for Image Processing*, in Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR) (2022), pp. 5769–5780.
 - [2] R. A. Jacobs, M. I. Jordan, S. J. Nowlan, and G. E. Hinton, *Adaptive Mixtures of Local Experts*, Neural Comput. **3**, 79 (1991).
 - [3] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean, *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer*, in Proc. Int. Conf. on Learning Representations (ICLR) (2017).
 - [4] W. Fedus, B. Zoph, and N. Shazeer, *Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity*, J. Mach. Learn. Res. **23**, 1 (2022).
 - [5] S. Nah, T. H. Kim, and K. M. Lee, *Deep Multi-scale Convolutional Neural Network for Dynamic Scene Deblurring*, in Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) (2017).
 - [6] C. Wei, W. Wang, W. Yang, and J. Liu, *Deep Retinex Decomposition for Low-Light Enhancement*, in Proc. British Machine Vision Conference (BMVC) (2018).
 - [7] A. Abdelhamed, S. Lin, and M. S. Brown, *A High-Quality Denoising Dataset for Smartphone Cameras*, in Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) (2018).
 - [8] B. Li, W. Ren, D. Fu, D. Tao, D. Feng, W. Zeng, and Z. Wang, *Benchmarking Single-Image Dehazing and Beyond*, IEEE Trans. Image Process. **28**, 492 (2019).
 - [9] X. Fu, J. Huang, D. Zeng, Y. Huang, X. Ding, and J. Paisley, *Removing Rain from Single Images via a Deep Detail Network*, in Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) (2017).
 - [10] I. Loshchilov and F. Hutter, *Decoupled Weight Decay Regularization*, in Proc. Int. Conf. on Learning Representations (ICLR) (2019).
 - [11] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, *Image Quality Assessment: From Error Visibility to Structural Similarity*, IEEE Trans. Image Process. **13**, 600 (2004).
 - [12] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, *The Unreasonable Effectiveness of Deep Features as a Perceptual Metric*, in Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR) (2018).
 - [13] J. Bradbury, R. Frostig, P. Hawkins, M. J. Johnson, C. Leary, D. Maclaurin, G. Necula, A. Paszke, J. VanderPlas, S. Wanderman-Milne, and Q. Zhang, *JAX: Composable Transformations of Python+NumPy Programs* (2018), <http://github.com/google/jax>.
 - [14] J. Heek, A. Levskaya, A. Oliver, M. Ritter, B. Rondepierre, A. Steiner, and M. van Zee, *Flax: A Neural Network Library and Ecosystem for JAX* (2023), <http://github.com/google/flax>.